



Universidade do Minho

Mestrado em [Engenharia Informática / Inteligência Artificial /
Engenharia e Ciência de Dados]

Aprendizagem Profunda

1º Ano, 2º Semestre

Ano letivo 2025/2026

Trabalho prático de grupo – Modulo 2

Docente: Victor Alves

Abril, 2026

Tema

Classificação Automática de Imagens Fluoroscópicas de CPRE via Deep Learning – Conceção e otimização de uma solução de visão por computador para identificação de patologias biliares e pancreáticas.

Contexto do Trabalho

A Colangiopancreatografia Retrógrada Endoscópica (CPRE) é um procedimento intervencionista complexo que utiliza fluoroscopia (raios-X em tempo real). A interpretação destas imagens é desafiante e crucial para o sucesso do procedimento. O dataset MIQR-CC (Multimodal Image Quality and Risk in ERCP and Colonoscopy) disponibiliza milhares de imagens curadas e anotadas por especialistas, permitindo o desenvolvimento de sistemas de suporte à decisão clínica (CADx).

O objetivo deste trabalho consiste em desenvolver modelos capazes de classificar automaticamente imagens de CPRE em categorias diagnósticas críticas:

- Biliary_Leaks (Bile Leaks, Fugas de bÍlis)
- Lithiasis (Biliary lithiasis, Stones, Cálculos/Pedras)
- Stricture (Strictures, Estenoses/Aperto dos ductos)
- Normal (Achados normais)

Objetivos de Aprendizagem

Com a realização deste trabalho prático pretende-se sensibilizar e motivar os alunos para a resolução de problemas concretos utilizando as técnicas abordados na UC aplicadas à imagem médica. Especificamente, pretende-se:

- Dominar o fluxo de trabalho com imagens médicas (DICOM/PNG) e metadados.
- Aplicar, comparar e afinar arquiteturas de DL (e.g. CNNs, Vision Transformers) para classificação multi-classe.
- Lidar com datasets desbalanceados, (comum na área médica) através de técnicas de aumento de dados (Augmentation), funções de perda ponderadas e funções de perda assimétricas.
- Implementar métricas de avaliação robustas (F1-Score, Matrizes de Confusão, AUC-ROC).
- Garantir a reprodutibilidade e interpretabilidade dos modelos (ex: Grad-CAM).

Enunciado

Propõe-se o desenvolvimento de uma solução computacional baseada em Deep Learning para a classificação automática de imagens de CPRE, utilizando como base o artigo "Curated endoscopic retrograde cholangiopancreatography images dataset (MIQR-CC)" <https://doi.org/10.6084/m9.figshare.31079236> e o correspondente *dataset* disponível em <https://figshare.com/ndownloader/files/61063177>

As tarefas incluem:

- Análise Exploratória: Estudo da distribuição das classes e preparação do dataset (split treino/validação/teste).
- Desenvolvimento de uma solução tendo como *baseline* as soluções e os resultados referidos no artigo e disponíveis em <https://github.com/monicacmartins/MIQR-CC-Dataset>
- Otimização: Exploração de técnicas avançadas como *Transfer Learning*, *Fine-tuning* de modelos SOTA ou arquiteturas híbridas.
- Avaliação: Comparação rigorosa dos resultados face à *baseline* apresentada no artigo (F1-score macro de 0.738).
- Interpretabilidade (Obrigatório): Geração de mapas de calor (heatmaps) para identificar as regiões da imagem que influenciaram a classificação do modelo.

O sistema de IA deve ser capaz de processar imagens de entrada e fornecer:

- Previsão Multi-classe: Probabilidades para as 4 classes principais;
- Robustez ao Ruído: Lidar com variações de contraste e artefactos comuns em raios-X;
- Explicação Visual: Visualização das áreas críticas detetadas (ex: localização da estenose ou do cálculo).

Metodologia

Os alunos devem basear o seu desenvolvimento no repositório oficial e nos dados disponibilizados:

- Acesso aos Dados: O *dataset* está disponível via Figshare (<https://doi.org/10.6084/m9.figshare.31079236>). Devem utilizar as versões processadas das imagens.
- Revisão da Baseline: Consultar o código disponível no GitHub (<https://github.com/monicacmartins/MIQR-CC-Dataset>) para compreender o pipeline de pré-processamento.

Workflow Sugerido:

- Pré-processamento (e.g. Redimensionamento, Normalização, CLAHE (Contrast Limited Adaptive Histogram Equalization)).
- Implementação de estratégias para lidar com o desequilíbrio (ex: Class Weights ou Oversampling).
- Treino de modelos candidatos.
- Validação e avaliação utilizando o *hold-out* (treino, validação e teste) disponibilizado.

Entrega e Avaliação

Os resultados devem ser apresentados num relatório técnico (máx. 10 páginas) escrita seguindo o *template* da Springer para artigos de conferência, contendo:

- Metodologia de tratamento de imagem (pré-processamento).
- Arquitetura detalhada dos modelos e hiperparâmetros.
- Análise comparativa (Tabelas de métricas e Matrizes de Confusão), devendo salientar o F1-Score(macro) obtido nos casos deteste.
- Exemplos de visualização de interpretabilidade (Grad-CAM).

O relatório, assim como um ficheiro zip com o repositório GitHub usado, com instruções de execução (README) e requisitos (requirements.txt) acompanhado de exemplos e indicações que permitam reproduzir todos os passos realizados assim como os resultados obtidos deverá ser submetido, por um elemento do grupo, na plataforma de e-learning da Universidade do Minho (em “*Conteúdo/Modulo 2/ Projeto de Grupo – M2/ Submissão do Trabalho de Grupo*”). As submissões deverão ser realizadas até ao final do dia **31 de maio de 2026**.

Na semana de 25/maio a 30/maio, no período da aula decorrerão as sessões de apresentação e discussão do trabalho desenvolvido. Os grupos de trabalho deverão submeter antecipadamente as suas apresentações na plataforma de e-learning da Universidade do Minho (em “*Conteúdo/Modulo 2/ Projeto de Grupo – M2/ Submissão da apresentação*”). Cada grupo disporá de 15 minutos para realizar a apresentação, utilizando os meios que considerar mais adequados.

Nota Pedagógica

Este trabalho segue a filosofia challenge-based learning. Os alunos são encorajados a:

- Tentar superar a baseline do artigo original (F1-score > 0.738).
- Refletir sobre as implicações clínicas de falsos negativos em patologias graves (ex: estenoses).
- Utilizar ferramentas de *tracking* de experiências (ex: WandB ou MLFlow) para documentar a evolução do treino.

Observação:

O *dataset* MIQR-CC é particularmente desafiante devido à semelhança visual entre certas patologias sob fluoroscopia. Sugere-se o uso de técnicas de *Attention Maps* para verificar se o modelo está focado nos ductos biliares ou em artefactos externos.

Avaliação por Pares

Cada grupo deve realizar uma análise coletiva da contribuição e do esforço que cada membro dedicou ao desenvolvimento do trabalho. A partir dessa análise, devem ser identificados os membros que trabalharam acima, na média e abaixo da média. Para esta componente de avaliação, é atribuído 1 valor para cada estudante, refletindo a sua contribuição individual para o desenvolvimento desta ferramenta de avaliação.

Assim, um dos membros do grupo deve enviar um e-mail, com os outros membros em CC, para valves@di.uminho.pt. O assunto deve ser "**AP[*curso*] – TG - Avaliação Por Pares**" em que "*curso*" deve ser substituído pelo correspondente curso (MEI, MIA ou MECD).

No corpo do e-mail, relativamente a cada elemento do grupo deve estar indicado o seu delta (o valor a ser adicionado à nota desta componente). Ter em atenção que os deltas podem ser negativos, zero ou positivos e que, dentro de cada grupo, a soma dos deltas deve ser sempre igual a 0.00.

Exemplo 1 (corresponde a um esforço igual de todos):

PG1234 João DELTA = 0

PG5678 António DELTA = 0

PG9123 Maria DELTA = 0

PG4567 Rita DELTA = 0

Exemplo 2 (António recebe 1 valor adicional, Rita mantém a classificação, João e Maria perdem 0.5 valores cada):

PG1234 João DELTA = -0.5

PG5678 António DELTA = 1

PG9123 Maria DELTA = -0.5

PG4567 Rita DELTA = 0

Código de Conduta

Os participantes do presente trabalho académico declaram ter atuado com integridade e confirmam que não recorreram à prática de plágio nem a qualquer forma de utilização indevida ou falsificação de informações ou resultados em nenhuma das etapas conducente à sua elaboração. Mais declaram que conhecem e respeitaram o Código de Conduta Ética da Universidade do Minho.